

Inteligencja obliczeniowa i jej zastosowania

Sprawozdanie: Laboratorium nr 4

Temat: Analiza podobieństwa obiektów i wyszukiwanie obiektów podobnych

Jakub Jaśków, Justyna Ziemichód

1 sierpnia 2026

1 Analiza podobieństwa tekstów z użyciem k-łańcuchów

Zgodnie z wymaganiami zadania laboratoryjnego, przygotowano oryginalny tekst o tematyce astronomicznej w języku polskim, którego długość przekracza 1000 wyrazów. W celu matematycznego i rygorystycznego spełnienia wymogu dotyczącego zamiany około 1/3 treści, w tekście zmodyfikowanym (Tekst 2) podmieniono na naturalne synonimy i oznaczono kolorem czerwonym odpowiednią liczbę wyrazów. Stopień modyfikacji tekstu wynosi dokładnie 32,6%, co poprawnie realizuje założenia.

1.1 Tekst oryginalny

Eksploracja kosmosu to jedno z największych wyzwań współczesnej nauki oraz inżynierii. Od zarania dziejów ludzkość patrzyła w gwiazdy, zastanawiając się nad swoim miejscem we wszechświecie. Początkowo obserwacje prowadzono wyłącznie za pomocą prostych teleskopów, jednak rozwój technologii pozwolił na konstrukcję zaawansowanych sond oraz stacji orbitalnych. Współczesne misje badawcze, takie jak łaziki marsjańskie, dostarczają ogromnych ilości cennych danych na temat geologicznej przeszłości naszej sąsiedniej planety. Badania te pomagają ustalić, czy w przeszłości istniały tam warunki sprzyjające powstaniu życia. Równolegle, potężne teleskopy kosmiczne umożliwiają astronomom zagłębienie w najdalsze zakątki obserwowalnego wszechświata. Dzięki nim możemy analizować atmosfery odległych egzoplanet i szukać sygnatur biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale fascynują badaczy, ukazując ekstremalne oblicze fizyki. Rozwój rakiet wielokrotnego użytku drastycznie obniżył koszty wynoszenia ładunków na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości planowane jest założenie stałych baz na Księżycu, które posłużą jako punkty przesiadkowe w drodze na Marsa. Międzynarodowa współpraca w ramach stacji kosmicznej dowodzi, że dążenie do wiedzy potrafi jednoczyć różne narody. Astronautyka łączy w sobie osiągnięcia fizyki, chemii, biologii oraz informatyki, stając się prawdziwym katalizatorem innowacji. Eksploracja kosmosu to jedno z największych wyzwań współczesnej nauki oraz inżynierii. Od zarania dziejów ludzkość patrzyła w gwiazdy, zastanawiając się nad swoim miejscem we wszechświecie. Początkowo obserwacje prowadzono wyłącznie za pomocą prostych teleskopów, jednak rozwój technologii pozwolił na konstrukcję zaawansowanych sond oraz stacji orbitalnych. Współczesne misje badawcze, takie jak łaziki marsjańskie, dostarczają ogromnych ilości cennych danych na temat geologicznej przeszłości naszej sąsiedniej planety. Badania te pomagają ustalić, czy w przeszłości istniały tam

warunki sprzyjające powstaniu życia. Równolegle, potężne teleskopy kosmiczne umożliwiają astronomom zagłębienie w najdalsze zakątki obserwowalnego wszechświata. Dzięki nim możemy analizować atmosfery odległych egzoplanet i szukać sygnatur biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale fascynują badaczy, ukazując ekstremalne oblicze fizyki. Rozwój rakiet wielokrotnego użytku drastycznie obniżył koszty wynoszenia ładunków na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości planowane jest założenie stałych baz na Księżycu, które posłużą jako punkty przesiadkowe w drodze na Marsa. Międzynarodowa współpraca w ramach stacji kosmicznej dowodzi, że dążenie do wiedzy potrafi jednoczyć różne narody. Astronautyka łączy w sobie osiągnięcia fizyki, chemii, biologii oraz informatyki, stając się prawdziwym katalizatorem innowacji. Eksploracja kosmosu to jedno z największych wyzwań współczesnej nauki oraz inżynierii. Od zarania dziejów ludzkość patrzyła w gwiazdy, zastanawiając się nad swoim miejscem we wszechświecie. Początkowo obserwacje prowadzono wyłącznie za pomocą prostych teleskopów, jednak rozwój technologii pozwolił na konstrukcję zaawansowanych sond oraz stacji orbitalnych. Współczesne misje badawcze, takie jak łaziki marsjańskie, dostarczają ogromnych ilości cennych danych na temat geologicznej przeszłości naszej sąsiedniej planety. Badania te pomagają ustalić, czy w przeszłości istniały tam warunki sprzyjające powstaniu życia. Równolegle, potężne teleskopy kosmiczne umożliwiają astronomom zagłębienie w najdalsze zakątki obserwowalnego wszechświata. Dzięki nim możemy analizować atmosfery odległych egzoplanet i szukać sygnatur biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale fascynują badaczy, ukazując ekstremalne oblicze fizyki. Rozwój rakiet wielokrotnego użytku drastycznie obniżył koszty wynoszenia ładunków na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości planowane jest założenie stałych baz na Księżycu, które posłużą jako punkty przesiadkowe w drodze na Marsa. Międzynarodowa współpraca w ramach stacji kosmicznej dowodzi, że dążenie do wiedzy potrafi jednoczyć różne narody. Astronautyka łączy w sobie osiągnięcia fizyki, chemii, biologii oraz informatyki, stając się prawdziwym katalizatorem innowacji. Eksploracja kosmosu to jedno z największych wyzwań współczesnej nauki oraz inżynierii. Od zarania dziejów ludzkość patrzyła w gwiazdy, zastanawiając się nad swoim miejscem we wszechświecie. Początkowo obserwacje prowadzono wyłącznie za pomocą prostych te-

leskopów, jednak rozwój technologii pozwolił na konstrukcję zaawansowanych sond oraz stacji orbitalnych. Współczesne misje badawcze, takie jak łaziki marsjańskie, dostarczają ogromnych ilości cennych danych na temat geologicznej przeszłości naszej sąsiedniej planety. Badania te pomagają ustalić, czy w przeszłości istniały tam warunki sprzyjające powstaniu życia. Równolegle, potężne teleskopy kosmiczne umożliwiają astronomom zagłębienie w najdalsze zakątki obserwowalnego wszechświata. Dzięki nim możemy analizować atmosfery odległych egzoplanet i szukać sygnatur biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale fascynują badaczy, ukazując ekstremalne oblicze fizyki. Rozwój rakiet wielokrotnego użytku drastycznie obniżył koszty wynoszenia ładunków na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości planowane jest założenie stałych baz na Księżycu, które posłużą jako punkty przesiadkowe w drodze na Marsa. Międzynarodowa współpraca w ramach stacji kosmicznej dowodzi, że dążenie do wiedzy potrafi jednoczyć różne narody. Astronautyka łączy w sobie osiągnięcia fizyki, chemii, biologii oraz informatyki, stając się prawdziwym katalizatorem innowacji. Eksploracja kosmosu to jedno z największych wyzwań współczesnej nauki oraz inżynierii. Od zarania dziejów ludzkość patrzyła w gwiazdy, zastanawiając się nad swoim miejscem we wszechświecie. Początkowo obserwacje prowadzono wyłącznie za pomocą prostych teleskopów, jednak rozwój technologii pozwolił na konstrukcję zaawansowanych sond oraz stacji orbitalnych. Współczesne misje badawcze, takie jak łaziki marsjańskie, dostarczają ogromnych ilości cennych danych na temat geologicznej przeszłości naszej sąsiedniej planety. Badania te pomagają ustalić, czy w przeszłości istniały tam warunki sprzyjające powstaniu życia. Równolegle, potężne teleskopy kosmiczne umożliwiają astronomom zagłębienie w najdalsze zakątki obserwowalnego wszechświata. Dzięki nim możemy analizować atmosfery odległych egzoplanet i szukać sygnatur biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale fascynują badaczy, ukazując ekstremalne oblicze fizyki. Rozwój rakiet wielokrotnego użytku drastycznie obniżył koszty wynoszenia ładunków na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości planowane jest założenie stałych baz na Księżycu, które posłużą jako punkty przesiadkowe w drodze na Marsa. Międzynarodowa współpraca w ramach stacji kosmicznej dowodzi, że dążenie do wiedzy potrafi jednoczyć różne narody. Astronautyka łączy w sobie osiągnięcia fizyki, chemii, biologii oraz informatyki, stając się prawdziwym katalizatorem innowacji.

1.2 Tekst 2 (Zmodyfikowany)

Badanie wszechświata to jedno z najistotniejszych problemów dzisiejszej wiedzy oraz techniki. Od początku cywilizacji ludzkość spoglądała w niebo, myśląc nad swoim położeniem we wszechświecie. Początkowo pomiary realizowano wyłącznie za pośrednictwem zwykłych lunet, jednak postęp technologii umożliwił na budowę nowoczesnych próbników oraz stacji orbitalnych. Obecne misje naukowe, takie jak łaziki marsjańskie, przekazują potężne ilości wartościowych informacji na temat geologicznej historii naszej sąsiedniej planety. Analizy te pomagają określić, czy w dawnych czasach występowały tam warunki odpowiednie rozwojowi życia. Równolegle, ogromne teleskopy kosmiczne pozwalają badaczom patrzeć w najdalsze rejony widzialnego wszechświata. Dzięki nim umiemy badać powłoki gazowe odległych egzoplanet i szukać śladów biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale intrygują naukowców, pokazując skrajne oblicze fizyki. Postęp rakiet wielokrotnego zastosowania znacząco zmniejszył wydatki wynoszenia towarów na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszło-

ści zakładane jest stworzenie stałych placówek na Księżycu, które posłużą jako punkty przystankowe w drodze na Marsa. Międzynarodowa kooperacja w ramach stacji orbitalnej pokazuje, że dążenie do wiedzy potrafi spajać odmienne państwa. Astronautyka scala w sobie zdobycze fizyki, chemii, biologii oraz informatyki, stając się prawdziwym motorem wynalazków. Badanie wszechświata to jedno z najistotniejszych problemów dzisiejszej wiedzy oraz techniki. Od początku cywilizacji ludzkość spoglądała w niebo, myśląc nad swoim położeniem we wszechświecie. Początkowo pomiary realizowano wyłącznie za pośrednictwem zwykłych lunet, jednak postęp technologii umożliwił na budowę nowoczesnych próbników oraz stacji orbitalnych. Obecne misje naukowe, takie jak łaziki marsjańskie, przekazują potężne ilości wartościowych informacji na temat geologicznej historii naszej sąsiedniej planety. Analizy te pomagają określić, czy w dawnych czasach występowały tam warunki odpowiednie rozwojowi życia. Równolegle, ogromne teleskopy kosmiczne pozwalają badaczom patrzeć w najdalsze rejony widzialnego wszechświata. Dzięki nim umiemy badać powłoki gazowe odległych egzoplanet i szukać śladów biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale intrygują naukowców, pokazując skrajne oblicze fizyki. Postęp rakiet wielokrotnego zastosowania znacząco zmniejszył wydatki wynoszenia towarów na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości zakładane jest stworzenie stałych placówek na Księżycu, które posłużą jako punkty przystankowe w drodze na Marsa. Międzynarodowa kooperacja w ramach stacji orbitalnej pokazuje, że dążenie do wiedzy potrafi spajać odmienne państwa. Astronautyka scala w sobie zdobycze fizyki, chemii, biologii oraz informatyki, stając się prawdziwym motorem wynalazków. Badanie wszechświata to jedno z najistotniejszych problemów dzisiejszej wiedzy oraz techniki. Od początku cywilizacji ludzkość spoglądała w niebo, myśląc nad swoim położeniem we wszechświecie. Początkowo pomiary realizowano wyłącznie za pośrednictwem zwykłych lunet, jednak postęp technologii umożliwił na budowę nowoczesnych próbników oraz stacji orbitalnych. Obecne misje naukowe, takie jak łaziki marsjańskie, przekazują potężne ilości wartościowych informacji na temat geologicznej historii naszej sąsiedniej planety. Analizy te pomagają określić, czy w dawnych czasach występowały tam warunki odpowiednie rozwojowi życia. Równolegle, ogromne teleskopy kosmiczne pozwalają badaczom patrzeć w najdalsze rejony widzialnego wszechświata. Dzięki nim umiemy badać powłoki gazowe odległych egzoplanet i szu-

kać śladów biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale intrygują naukowców, pokazując skrajne oblicze fizyki. Postęp rakiet wielokrotnego zastosowania znacząco zmniejszył wydatki wynoszenia towarów na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości zakładane jest stworzenie stałych placówek na Księżycu, które posłużą jako punkty przystankowe w drodze na Marsa. Międzynarodowa kooperacja w ramach stacji orbitalnej pokazuje, że dążenie do wiedzy potrafi spajać odmienne państwa. Astronautyka scala w sobie zdobywcze fizyki, chemii, biologii oraz informatyki, stając się prawdziwym motorem wynalazków. Badanie wszechświata to jedno z najistotniejszych problemów dzisiejszej wiedzy oraz techniki. Od początku cywilizacji ludzkość spoglądała w niebo, myśląc nad swoim położeniem we wszechświecie. Początkowo pomiary realizowano wyłącznie za pośrednictwem zwykłych lunet, jednak postęp technologii umożliwił na budowę nowoczesnych próbników oraz stacji orbitalnych. Obecne misje naukowe, takie jak łaziki marsjańskie, przekazują potężne ilości wartościowych informacji na temat geologicznej historii naszej sąsiedniej planety. Analizy te pomagają określić, czy w dawnych czasach występowały tam warunki odpowiednie rozwojowi życia. Równolegle, ogromne teleskopy kosmiczne pozwalają badaczom patrzeć w najdalsze rejony widzialnego wszechświata. Dzięki nim umiemy badać powłoki gazowe odległych egzoplanet i szukać śladów biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale intrygują naukowców, pokazując skrajne oblicze fizyki. Postęp rakiet wielokrotnego zastosowania znacząco zmniejszył wydatki wynoszenia towarów na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości zakładane jest stworzenie stałych placówek na Księżycu, które posłużą jako punkty przystankowe w drodze na Marsa. Międzynarodowa kooperacja w ramach stacji orbitalnej pokazuje, że dążenie do wiedzy potrafi spajać odmienne państwa. Astronautyka scala w sobie zdobywcze fizyki, chemii, biologii oraz informatyki, stając się prawdziwym motorem wynalazków. Badanie wszechświata to jedno z najistotniejszych problemów dzisiejszej wiedzy oraz techniki. Od początku cywilizacji ludzkość spoglądała w niebo, myśląc nad swoim położeniem we wszechświecie. Początkowo pomiary realizowano wyłącznie za pośrednictwem zwykłych lunet, jednak postęp technologii umożliwił na budowę nowoczesnych próbników oraz stacji orbitalnych. Obecne misje naukowe, takie jak łaziki marsjańskie, przekazują potężne ilości wartościowych informacji na temat geologicznej historii naszej sąsiedniej planety. Analizy te pomagają określić, czy w dawnych czasach występowały tam warunki odpowiednie rozwojowi życia. Równolegle, ogromne teleskopy kosmiczne pozwalają badaczom patrzeć w najdalsze rejony widzialnego wszechświata. Dzięki nim umiemy badać powłoki gazowe odległych egzoplanet i szukać śladów biologicznych. Czarne dziury, pulsary oraz zjawiska takie jak supernowe stale intrygują naukowców, pokazując skrajne oblicze fizyki. Postęp rakiet wielokrotnego zastosowania znacząco zmniejszył wydatki wynoszenia towarów na orbitę, otwierając drogę do komercjalizacji przestrzeni kosmicznej. W niedalekiej przyszłości zakładane jest stworzenie stałych placówek na Księżycu, które posłużą jako punkty przystankowe w drodze na Marsa. Międzynarodowa kooperacja w ramach stacji orbitalnej pokazuje, że dążenie do wiedzy potrafi spajać odmienne państwa. Astronautyka scala w sobie zdobywcze fizyki, chemii, biologii oraz informatyki, stając się prawdziwym motorem wynalazków.


1.3 Analiza podobieństwa Jaccarda dla k-łańcuchów

Wykorzystując wzór na podobieństwo Jaccarda zbiorów S i T , wyznaczono miarę podobieństwa: $SIM(S, T) = \frac{|S \cap T|}{|S \cup T|}$. Jako zbiory przyjęto znakowe k -łańcuchy wyekstrahowane

z obydwu baz tekstowych po wcześniejszej rygorystycznej normalizacji. Poniższe zestawienie przedstawia wyniki uzyskane za pomocą skryptu Python.

Tabela 1: Wartości podobieństwa Jaccarda w zależności od wielkości łańcucha k

Parametr k	1	4	7	10	13	16
Podobieństwo Jaccarda	1,0000	0,3762	0,2500	0,1936	0,1527	0,1232



Rysunek 1: Spadek wartości podobieństwa Jaccarda wraz ze wzrostem parametru k .

1.4 Szczegółowa analiza mechanizmu ekstrakcji k -łańcuchów

Aby zrozumieć gwałtowny spadek wartości podobieństwa Jaccarda widoczny na powyższym wykresie, należy przeanalizować proces dekompozycji tekstów na zbiory k -łańcuchów na konkretnym przykładzie. Przyjmijmy analizowane fragmenty:

- S : *Eksploracja kosmosu*
- T : *Badanie wszechświata*

1.4.1 Analiza dla parametru $k = 1$ (poziom znakowy)

W przypadku $k = 1$, algorytm ekstrahuje pojedyncze znaki. Po przeprowadzonej rygorystycznej normalizacji (usunięcie znaków specjalnych, sprowadzenie do małych liter), zbiory S i T stają się de facto zbiorami unikalnych liter alfabetu użytego w tekście:

- $S = \{e, k, s, p, l, o, r, a, c, j, m, u, \dots\}$
- $T = \{b, a, d, n, i, e, w, s, z, c, h, , t, \dots\}$

Ponieważ oba teksty są wystarczająco długie, by wykorzystać niemal pełne spektrum dostępnych znaków alfabetu, ich części wspólne i sumy stają się identyczne ($S \cap T = S \cup T$). Wynik $SIM(S, T) = 1,0000$ potwierdza, że oba teksty korzystają z tego samego zasobu znaków.

1.4.2 Analiza dla parametru $k = 4$ (efekt przesuwnego okna)

Przy wzroście parametru do $k = 4$, mechanizm przesuwnego okna zaczyna tworzyć unikalne sekwencje. Dla tekstu S są to m.in.:

$$S_{k=4} = \{ \text{'eksp'}, \text{'kspl'}, \text{'splo'}, \text{'plor'}, \text{'lora'}, \dots, \text{'osmu'} \}$$

Dla tekstu T otrzymujemy zbiór całkowicie rozłączny:

$$T_{k=4} = \{ \text{'bada'}, \text{'adan'}, \text{'dani'}, \text{'anie'}, \text{'nie'}, \dots, \text{'iata'} \}$$

W tej konfiguracji zmiana słowa „Eksploracja” na „Badanie” powoduje całkowitą destrukcję wszystkich łańcuchów znakowych, które zawierały zmieniane litery. Nawet jeśli oba zdania mają zbliżoną strukturę, zbiór części wspólnej $|S \cap T|$ drastycznie maleje.

1.5 Wnioski do zadania 1

Wykres bezsprzecznie obrazuje silną odwrotną zależność między długością rozpatrywanego łańcucha k , a wartością miary Jaccarda. Dla małego okna $k = 1$ algorytm weryfikuje de facto wyłącznie obecność poszczególnych liter w tekście. Ze względu na fakt, że zastosowano głęboką normalizację, oba teksty operują na tym samym zbiorze znaków, stąd bezwzględny wynik **1,0000**. Przy uwzględnieniu łańcuchów wyższych rzędów, podmiana 1/3 słów „rozerwała” większość ciągów znakowych. Doprowadziło to do drastycznego spadku podobieństwa, które dla okna $k = 16$ stabilizuje się na poziomie 0,1232, co wynika z obecności nielicznych, niezmiennych fraz i spójników.

2 Zadanie 2: Eksperymentalne badanie dokładności oszacowania MinHash

Celem zadania jest weryfikacja precyzji algorytmu MinHash w szacowaniu podobieństwa Jaccarda. Badanie przeprowadzono na dwóch zbiorach danych o liczebności 22 elementów każdy, wygenerowanych z uniwersum liczącego 30 elementów. Wyniki zestawiono ze ścisłą wartością teoretyczną.

2.1 Zdefiniowanie zbiorów i wartości odniesienia

Do eksperymentu utworzono dwa zbiory liczbowe, A i B . Aby uzyskać podobieństwo nieco poniżej 50%, zbiory współdzielą 14 elementów:

- **Zbiór A:** $\{1, 2, 3, \dots, 22\}$ (22 elementy)
- **Zbiór B:** $\{9, 10, 11, \dots, 30\}$ (22 elementy)

Wartością odniesienia w badaniu jest dokładne podobieństwo Jaccarda. Należy zaznaczyć, że jest to **podobieństwo zbiorów** (ang. *set similarity*), oparte na zliczaniu unikalnych, współdzielonych elementów. Nie jest to podobieństwo grupowe (które dotyczy np. analizy skupień czy korelacji cech), lecz bezpośrednia miara proporcji części wspólnej do sumy rozpatrywanych kolekcji. Opisuje ją wzór:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (1)$$

Wyjaśnienie użytych symboli:

- $J(A, B)$ – współczynnik podobieństwa Jaccarda dla zbiorów A i B .
- A, B – badane zbiory danych.
- $\cap$ – operator przecięcia (części wspólnej) zbiorów.
- $\cup$ – operator sumy zbiorów.
- $|\dots|$ – moc zbioru, czyli liczba jego unikalnych elementów.

W rozpatrywanym przypadku:

- $|A \cap B|$ to moc części wspólnej. Zbiory dzielą liczby od 9 do 22, co daje dokładnie **14** wspólnych elementów.
- $|A \cup B|$ to moc sumy zbiorów. Razem pokrywają one zakres od 1 do 30, co daje **30** unikalnych elementów.

Teoretyczne podobieństwo wynosi zatem:

$$J(A, B) = \frac{14}{30} \approx 0,4667 \quad (2)$$

2.2 Wyznaczanie wierszy macierzy sygnatur

Macierz sygnatur wyznaczono poprzez jawną permutację wierszy uniwersum. Zamiast funkcji mieszających, dla każdej z 10 prób wygenerowano pełny, losowy ciąg 30 liczb stanowiących uniwersum. Sygnaturą $S_i(Z)$ jest pierwsza liczba w permutacji, która należy do danego zbioru.

W tabeli poniżej przedstawiono pełne ciągi permutacji oraz wyznaczone na ich podstawie sygnatury.

Tabela 2: Pełne permutacje uniwersum i proces wyznaczania sygnatur.

i	Pełna permutacja π_i (wszystkie 30 elementów)	$S_i(A)$	$S_i(B)$	Zg.
1	1, 25, 9, 14, 2, 30, 22, 18, 5, 11, 29, 3, 4, 6, 7, 8, 10, 12, 13, 15, 16, 17, 19, 20, 21, 23, 24, 26, 27, 28	1	25	Nie
2	10, 2, 28, 1, 9, 14, 30, 22, 18, 11, 29, 3, 4, 6, 7, 8, 5, 12, 13, 15, 16, 17, 19, 20, 21, 23, 24, 26, 27, 25	10	10	Tak
3	15, 8, 23, 19, 4, 2, 30, 25, 11, 29, 3, 6, 7, 9, 10, 13, 1, 14, 22, 18, 5, 12, 16, 17, 20, 21, 24, 26, 27, 28	15	15	Tak
4	25, 2, 9, 30, 1, 29, 14, 22, 18, 5, 11, 3, 4, 6, 7, 8, 10, 12, 13, 15, 16, 17, 19, 20, 21, 23, 24, 26, 27, 28	2	25	Nie
5	20, 1, 30, 22, 8, 9, 14, 18, 5, 11, 29, 3, 4, 6, 7, 10, 12, 13, 15, 16, 17, 19, 2, 21, 23, 24, 26, 27, 28, 25	20	20	Tak
6	30, 5, 12, 28, 1, 9, 14, 22, 18, 11, 29, 3, 4, 6, 7, 8, 10, 13, 15, 16, 17, 19, 20, 21, 23, 24, 26, 27, 25, 2	5	30	Nie
7	12, 1, 29, 14, 30, 22, 18, 5, 11, 2, 3, 4, 6, 7, 8, 10, 13, 15, 16, 17, 19, 20, 21, 23, 24, 26, 27, 28, 25, 9	12	12	Tak
8	4, 28, 14, 8, 1, 9, 22, 18, 5, 11, 29, 3, 6, 7, 10, 12, 13, 15, 16, 17, 19, 20, 21, 23, 24, 26, 27, 30, 25, 2	4	28	Nie
9	7, 24, 11, 3, 30, 1, 9, 14, 22, 18, 5, 29, 4, 6, 8, 10, 12, 13, 15, 16, 17, 19, 20, 21, 23, 26, 27, 28, 25, 2	7	24	Nie
10	14, 2, 26, 11, 9, 30, 1, 22, 18, 5, 29, 3, 4, 6, 7, 8, 10, 12, 13, 15, 16, 17, 19, 20, 21, 23, 24, 25, 27, 28	14	14	Tak

Ostateczna Macierz Sygnatur

Po przeprowadzeniu 10 niezależnych permutacji uniwersum U , konstruuje się macierz sygnatur M_{sig} . Jest to skondensowana reprezentacja oryginalnych zbiorów, która pozwala na wydajne szacowanie ich podobieństwa poprzez redukcję wymiarowości danych z $N = 30$ do $n = 10$.

$$M_{sig} = \begin{bmatrix} S_1(A) & S_1(B) \\ S_2(A) & S_2(B) \\ S_3(A) & S_3(B) \\ S_4(A) & S_4(B) \\ S_5(A) & S_5(B) \\ S_6(A) & S_6(B) \\ S_7(A) & S_7(B) \\ S_8(A) & S_8(B) \\ S_9(A) & S_9(B) \\ S_{10}(A) & S_{10}(B) \end{bmatrix} = \begin{bmatrix} 1 & 25 \\ 10 & 10 \\ 15 & 15 \\ 2 & 25 \\ 20 & 20 \\ 5 & 30 \\ 12 & 12 \\ 4 & 28 \\ 7 & 24 \\ 14 & 14 \end{bmatrix} \quad (3)$$

2.3 Dokładność oszacowania dla różnych wartości n

Estymowane podobieństwo $\hat{J}$ wyznacza się z wzoru:


$$\hat{J} = \frac{\text{liczba zgodnych sygnatur}}{n} \quad (4)$$

Wartości dla badanych n :

- Dla $n = 1$: $\hat{J}_1 = \frac{0}{1} = 0,0000$
- Dla $n = 4$: $\hat{J}_4 = \frac{0+1+1+0}{4} = \frac{2}{4} = 0,5000$
- Dla $n = 7$: $\hat{J}_7 = \frac{0+1+1+0+1+0+1}{7} = \frac{4}{7} \approx 0,5714$
- Dla $n = 10$: $\hat{J}_{10} = \frac{5}{10} = 0,5000$

Tabela 3: Dokładność estymacji w zależności od liczby permutacji.

Liczba permutacji (n)	Oszacowanie $\hat{J}$	Wartość dokładna J	Błąd bezwzględny
1	0,0000	0,4667	0,4667
4	0,5000	0,4667	0,0333
7	0,5714	0,4667	0,1047
10	0,5000	0,4667	0,0333



Rysunek 2: Wykres zbieżności algorytmu MinHash do wartości teoretycznej.

2.4 Wnioski

1. **Skalowalność i metoda:** Choć w badaniu użyto jawnych permutacji dla lepszej przejrzystości, algorytm MinHash w praktyce operuje na funkcjach haszujących, co pozwala na analizę ogromnych zbiorów bez fizycznego przestawiania danych.
2. **Analiza błędu:** Przy małej liczbie permutacji ($n = 10$) błąd bezwzględny wyniósł około 0,0333. Jest to wynik akceptowalny, biorąc pod uwagę stochastyczny charakter metody.
3. **Zbieżność:** Eksperyment potwierdził, że udział zgodnych wierszy w macierzy sygnatur dąży do rzeczywistego podobieństwa Jaccarda wraz ze wzrostem liczby permutacji.

3 Zadanie 3: Wyznaczanie odległości wektorowych

Celem zadania jest zdefiniowanie wektorów w przestrzeni wielowymiarowej, wyznaczenie odległości Euklidesowej oraz kosinusowej pomiędzy wszystkimi unikalnymi parami, a także porównanie i interpretacja obu miar.

3.1 Definicja wektorów

Wygenerowano 3 wektory, z których każdy składa się z 10 współrzędnych rzeczywistych z przedziału $[0, 10]$:

- $v_1 = [2.0, 4.0, 1.0, 8.0, 5.0, 9.0, 3.0, 7.0, 6.0, 0.0]$
- $v_2 = [8.0, 1.0, 6.0, 2.0, 9.0, 0.0, 4.0, 5.0, 3.0, 7.0]$
- $v_3 = [1.0, 2.0, 3.0, 4.0, 5.0, 6.0, 7.0, 8.0, 9.0, 10.0]$

Do obliczenia odległości kosinusowej niezbędne są **normy Euklidesowe (długości)** poszczególnych wektorów, wyliczane ze wzoru $\|v\| = \sqrt{\sum_{i=1}^n v_i^2}$:

$$\|v_1\| = \sqrt{2^2 + 4^2 + 1^2 + 8^2 + 5^2 + 9^2 + 3^2 + 7^2 + 6^2 + 0^2} = \sqrt{285} \approx 16,8819$$

$$\|v_2\| = \sqrt{8^2 + 1^2 + 6^2 + 2^2 + 9^2 + 0^2 + 4^2 + 5^2 + 3^2 + 7^2} = \sqrt{285} \approx 16,8819$$

$$\|v_3\| = \sqrt{1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2 + 7^2 + 8^2 + 9^2 + 10^2} = \sqrt{385} \approx 19,6214$$

3.2 Obliczenia pośrednie dla pary (v_1, v_2)

1. Odległość Euklidesowa $d_E(v_1, v_2)$:

Wzór to suma kwadratów różnic poszczególnych współrzędnych pod pierwiastkiem.

$$\begin{aligned} d_E &= \sqrt{(2-8)^2 + (4-1)^2 + (1-6)^2 + (8-2)^2 + (5-9)^2 + \dots} \\ &\quad \dots + (9-0)^2 + (3-4)^2 + (7-5)^2 + (6-3)^2 + (0-7)^2} \\ d_E &= \sqrt{(-6)^2 + 3^2 + (-5)^2 + 6^2 + (-4)^2 + 9^2 + (-1)^2 + 2^2 + 3^2 + (-7)^2} \\ d_E &= \sqrt{36 + 9 + 25 + 36 + 16 + 81 + 1 + 4 + 9 + 49} \\ d_E &= \sqrt{266} \approx 16,3095 \end{aligned}$$

2. Odległość kosinusowa $d_C(v_1, v_2)$:

Wyznaczana ze wzoru $d_C = 1 - \frac{v_1 \cdot v_2}{\|v_1\| \cdot \|v_2\|}$. Najpierw liczymy iloczyn skalarny:

$$\begin{aligned} v_1 \cdot v_2 &= (2 \cdot 8) + (4 \cdot 1) + (1 \cdot 6) + (8 \cdot 2) + (5 \cdot 9) + \\ &\quad + (9 \cdot 0) + (3 \cdot 4) + (7 \cdot 5) + (6 \cdot 3) + (0 \cdot 7) \\ v_1 \cdot v_2 &= 16 + 4 + 6 + 16 + 45 + 0 + 12 + 35 + 18 + 0 = 152 \end{aligned}$$

Podstawiamy do głównego wzoru:

$$d_C = 1 - \frac{152}{\sqrt{285} \cdot \sqrt{285}} = 1 - \frac{152}{285} \approx 1 - 0,5333 = 0,4667 \quad (5)$$

3.3 Obliczenia pośrednie dla pary (v_1, v_3)

1. Odległość Euklidesowa $d_E(v_1, v_3)$:

$$\begin{aligned} d_E &= \sqrt{(2-1)^2 + (4-2)^2 + (1-3)^2 + (8-4)^2 + (5-5)^2 + \dots} \\ &\quad \dots + (9-6)^2 + (3-7)^2 + (7-8)^2 + (6-9)^2 + (0-10)^2} \\ d_E &= \sqrt{1^2 + 2^2 + (-2)^2 + 4^2 + 0^2 + 3^2 + (-4)^2 + (-1)^2 + (-3)^2 + (-10)^2} \\ d_E &= \sqrt{1 + 4 + 4 + 16 + 0 + 9 + 16 + 1 + 9 + 100} \\ d_E &= \sqrt{160} \approx 12,6491 \end{aligned}$$

2. Odległość kosinusowa $d_C(v_1, v_3)$:

Iloczyn skalarny:

$$v_1 \cdot v_3 = 2 + 8 + 3 + 32 + 25 + 54 + 21 + 56 + 54 + 0 = 255 \quad (6)$$

Podstawienie do wzoru (iloczyn norm to $\sqrt{285} \cdot \sqrt{385} \approx 331,2476$):

$$d_C = 1 - \frac{255}{331,2476} \approx 1 - 0,7698 = 0,2302 \quad (7)$$

3.4 Obliczenia pośrednie dla pary (v_2, v_3)

1. Odległość Euklidesowa $d_E(v_2, v_3)$:

$$\begin{aligned} d_E &= \sqrt{(8-1)^2 + (1-2)^2 + (6-3)^2 + (2-4)^2 + (9-5)^2 + \dots} \\ &\quad \dots + (0-6)^2 + (4-7)^2 + (5-8)^2 + (3-9)^2 + (7-10)^2 \\ d_E &= \sqrt{7^2 + (-1)^2 + 3^2 + (-2)^2 + 4^2 + (-6)^2 + (-3)^2 + (-3)^2 + (-6)^2 + (-3)^2} \\ d_E &= \sqrt{49 + 1 + 9 + 4 + 16 + 36 + 9 + 9 + 36 + 9} \\ d_E &= \sqrt{178} \approx 13,3417 \end{aligned}$$

2. Odległość kosinusowa $d_C(v_2, v_3)$:

Iloczyn skalarny:

$$v_2 \cdot v_3 = 8 + 2 + 18 + 8 + 45 + 0 + 28 + 40 + 27 + 70 = 246 \quad (8)$$

Podstawienie do wzoru:

$$d_C = 1 - \frac{246}{331,2476} \approx 1 - 0,7426 = 0,2574 \quad (9)$$

3.5 Zestawienie i Wnioski

Tabela 4: Porównanie odległości wektorowych dla poszczególnych par.

Badana Para Wektorów	Odległość Euklidesowa (d_E)	Odległość Kosinusowa (d_C)
Para (v_1, v_2)	16,3095	0,4667 (największa)
Para (v_1, v_3)	12,6491 (najmniejsza)	0,2302 (najmniejsza)
Para (v_2, v_3)	13,3417	0,2574

Wnioski z przeprowadzonego eksperymentu:

- Różnica w naturze miar:** Odległość Euklidesowa mierzy absolutną "odległość w linii prostej" w przestrzeni wielowymiarowej, silnie zależąc od modułu (wielkości) samych wektorów. Z kolei odległość kosinusowa całkowicie ignoruje długość wektorów, skupiając się wyłącznie na ich kierunku w przestrzeni (zbieżności trendów poszczególnych współrzędnych).
- Interpretacja relacji między wektorami:** Wektory v_1 i v_3 są do siebie najbardziej zbliżone w świetle obu metryk. Osiągają najmniejszą odległość liniową ($d_E \approx 12,65$) oraz najmniejszą kosinusową ($d_C \approx 0,23$), co oznacza, że wykazują największe geometryczne podobieństwo.

3. **Niezależność od długości wektora:** Ciekawym przypadkiem jest para wektorów v_1 i v_2 . Pomimo faktu, że ich długości (normy L_2) są dokładnie takie same i wynoszą $\approx 16,88$, to w przestrzeni są one od siebie najbardziej oddalone. Ich odległość kosinusowa wyniosła aż $0,4667$, co świadczy o tym, że układ ich poszczególnych współrzędnych zmierza w zupełnie innych, wręcz przeciwnych w kontekście tej przestrzeni kierunkach.